

Agent Runtime 技术全景


Agent Runtime 技术概览

调研周期:2026-07-07 | 覆盖 72 开源项目 / 8 子领域 | 数据源:KG summary + codebase-memory 49 zst

一、背景:为什么 Agent Runtime 是一个独立的基础设施层

2024-2026 年,AI Agent 从” ChatGPT 的玩具” 变成生产级应用。但 Agent 不是 LLM API 调用者的简单封装——它是一个**自主生成代码、调用工具、跨多轮持久化状态的不可信进程**。这催生了一个全新的基础设施需求:Agent Runtime。

不同于 LLM 推理引擎(vLLM/SGLang/Triton)解决” 怎么高效跑模型” ,Agent Runtime 解决的是” 模型跑起来之后,怎么安全、可靠、可观测地让 Agent 与世界交互”。从 Agent 收到用户指令到返回最终结果的全链路,每一层都需要专门的运行时能力:



浏览器/API	追踪/评估/
外部世界交互	成本监控

二、关键问题全景:8 个子领域各自要解决什么

#	子领域	核心矛盾	项目数
1	Sandbox	Agent 生成不可信代码,「隔离强度」vs「启动速度」vs「运维成本」三元权衡	27
2	Memory	多轮/跨 session 的上下文持久化,「存储结构」vs「检索精度」的取舍	14
3	Gateway	多模型/多 Provider/多 Agent 之间的统一路由、协议转换、认证、成本归因	10
4	Observability	Agent 非确定性行为的追踪、评估、回归测试——没有 exception,只有不可靠的答案	10
5	Tool	Agent 如何与外部世界交互(浏览器/API/文件系统)?「发现-调用-解析」闭环	7
6	Protocol	Agent↔Tool(MCP)与 Agent↔Agent(A2A)的通信标准化	2
7	Planner	Agent 多步任务分解与执行,框架层还是运行时层?	1
8	Security	Agent 输入/输出的越狱/注入/有害内容/敏感信息泄露如何实时拦截	1

三、技术方向分类

3.1 Sandbox(执行隔离与安全)——27 项目

方向 1:MicroVM 硬件级隔离(安全优先)

以 Firecracker/Kata/gVisor 实现 VM 级安全边界,适合多租户、不可信代码。代表: - **E2B**(1219 ★):Agent 沙箱事实标杆,Firecracker microVM,<200ms 冷启动,API-first - **NVIDIA/OpenShell**(7434★):多后端(microVM/Podman/Docker/K8s),核心差异是凭据代理出口网关+GPU VFIO 直通 - **OpenSandbox**(11856 ★):协议驱动,5 语言 SDK+MCP 原生集成,Credential Vault

方向 2:容器级隔离(主流平衡点)

利用 Docker/K8s/Podman 成熟生态,启动快于 VM 但隔离弱于 VM。代表: - **kubernetes-sigs/agent-sandbox**(3077★):K8s 原生 Sandbox CRD 规范 - **coder**(13722★):Terraform 模板化开发环境,Terraform 模板化工作空间 - **CubeSandbox**(7986★):腾讯云容器安全增强,Rust 实现 - **cohere-terrarium**(312★):双运行时(Docker+Pyodide 浏览器端),最轻量

方向 3:进程级轻量隔离(速度优先)

利用 OS 原生安全基元(macOS Seatbelt/Linux bubblewrap/WASM),零基础设施依赖。代表: - **sandbox-runtime**(4592 ★):Claude Code 安全底座,npm 安装即用,无容器 - **DTVM**(158 ★):WASM 确定性执行,状态快照回滚 - **sandbox-sdk**(1059 ★):Cloudflare V8 isolates,毫秒启动,330+边缘节点

方向 4:安全策略、标准化与平台托管

在现有沙箱之上提供安全策略插件、标准化 API 或全托管平台。代表: - **agent-aegis**(173★):Agent 全生命周期安全防护插件 - **AWS Bedrock AgentCore 套件**(3 项目):全托管 Firecracker 沙箱平台 - **google/ax**(1838★):Google 分布式 Agent 运行时,DAG 任务调度 - **NemoClaw**(21629★):OpenShell 之上细粒度权限白名单,凭证不落盘

关键趋势:凭据管理与沙箱解耦(多项目不约而同让 Agent 看不到 API key)、多后端可插拔成为共识、OpenTelemetry 集成几乎成为标配。

3.2 Memory(状态与记忆管理)——14 项目

方向 1:记忆层框架(API-First)

独立于 Agent 框架的记忆中间层,提供标准 `add()/search()/update()` API。代表: - **mem0**(60253★):领域标杆,三层记忆+向量+图(Neo4j),记忆关系图是核心差异 - **memU**(13991★):

最结构化方案,六类定型抽取+Tool Memory+Salience 强化记忆 - **ReMe**(3159★):AgentScope 生态记忆工具包 - **TencentDB-Agent-Memory**(6831★):全本地部署,隐私优先,零云端依赖

方向 2:有状态 Agent(OS 级记忆管理)

将记忆嵌入 Agent 进程内部,Agent 自主管理”页面调度”。代表: - **letta**(23678★):学术先驱 (MemGPT),虚拟上下文管理,Self-Editing Memory - **powermem**(738★):OceanBase 出品,数据库基因(LSM-Tree+事务),数据可靠性优先

方向 3:混合索引与统一搜索

一引擎内融合向量+全文+图三种搜索范式。代表: - **OpenViking**(26377★):字节/火山的 Context DB,专为 Agent 设计 - **beads**(25125★):Go 原生三合一(HNSW+倒排+邻接表)嵌入式引擎

方向 4-7:RAG 平台 / 事件溯源 / 原文优先 / 后端基础设施

- **ragflow**(84446★):中文 RAG 标杆,DeepDoc 深度文档解析
- **mempalace**(57043★):**不做摘要不抽取不改写**,纯原文+层次结构,LongMemEval 96.6% R@5 第一
- **supabase**(105832★):PostgreSQL 底座一站式 Agent 后端
- **hindsight**(18062★):事件溯源引擎,不可变日志
- **seekdb**(2784★):分布式数据库内建 AI 搜索

核心争论:「原文优先 (mempalace)」 vs 「LLM 抽取 (mem0/memU)」——原文路线在 LongMemEval 上碾压摘要路线,但数万轮对话的存储成本和检索精度仍是未知数。

3.3 Gateway(API 与模型访问治理)——10 项目

方向 1:LLM 统一路由

一行代码换模型,Gateway 负责路由/负载均衡/故障转移。代表: - **LiteLLM**(52800★):事实标准,100+Provider,OpenAI 格式作为通用界面 - **New API**(41323★):国内最活跃,唯一实现 OpenAI-Claude-Gemini 双向格式互转 - **Higress**(8799★):阿里开源,Envoy Wasm 层 FNV-1a 一致性哈希 AI 路由 - **Envoy AI Gateway**(1813★):Envoy Filter 层透明拦截,与 Service Mesh 集成

方向 2:协议转换

OpenAI 兼容(路线 A,主流)vs 双向互转(路线 B,多 Agent 协作场景)。CC Switch(114028★)走桌面端配置级切换。

方向 3:认证与流控

双层认证 (Agent 侧+Provider 侧),流控从 QPS→RPM/TPM→Token 三级跃迁。Higress 的 Token 粒度方案最精细;MCP Gateway Registry(772★)的 6 IdP 联邦认证最灵活。

方向 4:MCP 网关注册

MCP Gateway Registry / Higress MCP Bridge / CC Switch 三种互补路线:注册中心 vs 网关内嵌 vs 桌面管理,尚未统一。

特殊项目:rtk(69019★,CLI proxy 减 Token 消耗 60-90%)和 agentgateway(3720★,Agentic Proxy for MCP)属于 GateWay 的创新边缘。

3.4 Observability(可观测性与评估)——10 项目

方向 1:全景追踪平台

像分布式追踪看微服务一样看 Agent。全部拥抱 OTel。代表: - **Langfuse**(30580★):最流行,Trace+Eval+Prompt Management 三位一体 - **Phoenix**(10423★):Arize 出品,OpenInference 语义约定+自动插桩 - **Opik**(20379★):Comet 出品,从 ML 实验到 LLM 追踪全栈连续性(93K 节点,最大代码库) - **OpenLIT**(2579★):GPU+LLM 全栈,填补 GPU 利用率/VRAM 监控缺口

方向 2:专项评估框架

将 LLM 质量评估包装为可编程 CI/CD 测试。代表: - **DeepEval**(16684★):pytest 式通用评估,15+ 指标 - **RAGAS**(14695★):RAG 专项评估手术刀,v2 扩展到 Agent 评估 - **LM Evaluation Harness**(13204★):模型基准,200+ 标准化任务

方向 3:安全评估

- **Promptfoo**(22986★):Red teaming,OpenAI 和 Anthropic 都在用
- **TruLens**(3423★):Snowflake 出品,OTel 原生+RAG 三合一+Agent 七维评估

关键洞察：三类平台正在趋同——Langfuse+RAGAS、Phoenix+DeepEval、Promptfoo+TruLens 都在构建”追踪→评估→改进”闭环。

3.5 Tool(工具集成与执行)——7 项目

方向 1:浏览器自动化

让 Agent 操作网页。代表：- **browser-use**(103174★):重量级完整功能,视觉+DOM 双模式 - **agent-browser**(37975★):Rust 轻量 CLI,Serverless 友好 - **browser-harness**(15778★):自愈型 harness,LLM 驱动修复 - **page-agent**(24675★):JS in-page GUI agent,纯前端路线

方向 2:网页内容提取

让 Agent 读懂网页。代表：- **firecrawl**(146442★):★最高,深度爬取+结构化提取+反反爬 - **reader**(11480★):jina.ai,URL→Markdown 零配置,Late Chunking

方向 3:工具集成平台

- **composio**(29118★):1000+工具集成,Managed Auth 托管认证是核心创新

趋势:DOM+VLM 混合定位成为共识,反检测能力是硬壁垒。

3.6 Protocol(Agent 间通信协议)——2 项目

核心分工：- **MCP**(8545★):Agent 的”手”——调用工具/数据/API,Anthropic 提出,已成事实标准 (月 SDK 下载 9700 万+) - **A2A**(24661★):Agent 的”社交名片”——互相发现/委托任务/交换结果,Google 提出,150+组织支持

两个协议**分层互补,非竞争**:MCP 解决 Agent”用什么”(垂直),A2A 解决”找谁”(水平)。2025.12 双双进入 Linux Foundation Agentic AI Foundation 统一治理。更广版图中还有 AGNTCY/ANP/ACP/AGTP/AP2 五协议在博弈。

3.7 Planner(规划与推理执行)——1 项目

gpt-researcher(28121★):自主深度研究 Agent。实现了 ReAct/Plan-and-Execute/Tree-of-Thought/Goth-of-Thought 等多种范式变体。2811 节点/7487 边,Python 实现。与 Sandbox(无隔离)、Memory(仅会话级)、Gateway(进程内紧耦合)在交叉点存在明确差距。

领域级技术方向包括六大范式:ReAct → Plan-and-Execute → Tree/Graph-of-Thought → Multi-Agent → Code/DSL 驱动(LangGraph)→ 端到端隐式规划。

3.8 Security(内容安全)——1 项目

llm-guard(3151★):输入/输出安全拦截。1455 节点/4296 边,21 种输入扫描器+25 种输出扫描器,支持 Vault 凭据脱敏/RiskScore/vLLM 兼容 API。三层防御模型:预处理(Guardrails)→后处理(LLM-Guard)→工具调用(Agent Aegis),覆盖 OWASP LLM Top 10(2025)中与内容安全相关的条目。

2025-2026 关键威胁:间接注入成为首要威胁,RL 攻击跨模型迁移(GPT-4o 被 RL-Hammer 达 98% 攻击成功率)。

四、项目全景图(72 项目速查)

项目	Sub	Stars	核心一句话
firecrawl	tool	146442	Web 抓取+结构化提取
cc-switch	gateway	114028	桌面端多工具 API 一键切换
supabase	memory	105832	PostgreSQL 底座一站式后端
browser-use	tool	103174	浏览器自动化标杆
ragflow	memory	84446	中文 RAG 标杆,DeepDoc
rtk	gateway	69019	CLI proxy,Token 减 60-90%
mem0	memory	60253	记忆层框架标杆
mempalace	memory	57043	纯原文,LongMemEval 第一
LiteLLM	gateway	52800	LLM 统一路由事实标准
New API	gateway	41323	唯一双向格式互转
agent-browser	tool	37975	Rust 轻量浏览器 CLI
Langfuse	observability	30580	最流行 Trace+Eval 平台
composio	tool	29118	1000+工具+Managed Auth
gpt-researcher	planner	28121	自主深度研究 Agent
OpenViking	memory	26377	字节火山 Context DB
beads	memory	25125	Go 三合一嵌入式引擎

项目	Sub	Stars	核心一句话
A2A	protocol	24661	Agent 间协作协议
page-agent	tool	24675	JS GUI agent,纯前端
letta	memory	23678	MemGPT 虚拟上下文管理
promptfoo	observability	22986	Red teaming 安全评估
NemoClaw	sandbox	21629	OpenShell 安全封装
Opik	observability	20379	ML 实验→LLM 追踪全栈
hindsight	memory	18062	事件溯源不可变日志
DeepEval	observability	16684	pytest 式通用评估
browser-harness	tool	15778	自愈型浏览器 harness
RAGAS	observability	14695	RAG 评估手术刀
memU	memory	13991	六类定型+Tool Memory
coder	sandbox	13722	Terraform 模板化开发环境
LM Eval Harness	observability	13204	200+模型基准任务
OpenSandbox	sandbox	11856	协议驱动+5SDK+MCP
reader	tool	11480	URL→Markdown 零配置
Phoenix	observability	10423	OpenInference+自动插桩
Higress	gateway	8799	Envoy Wasm AI 路由
MCP	protocol	8545	Agent↔Tool 协议,月下载 97M
CubeSandbox	sandbox	7986	腾讯云容器安全,Rust
OpenShell	sandbox	7434	凭据网关+GPU VFIO 直通
OpenLLMetry	observability	7275	OTel LLM Span 标准
TencentDB-Agent-Memory	memory	6831	全本地部署,零云端
kgateway	gateway	5597	云原生 API+AI Gateway
sandbox	sandbox	5353	All-in-One Docker 沙箱
AgentTeams	sandbox	5005	多 Agent 协作 OS
sandbox-runtime	sandbox	4592	Claude Code 进程级沙箱
agentgateway	gateway	3720	Agentic Proxy for MCP
TruLens	observability	3423	OTel 原生+Agent 七维评估

项目	Sub	Stars	核心一句话
agentcore-samples	sandbox	3166	AWS Bedrock AgentCore 示例
ReMe	memory	3159	AgentScope 记忆工具包
llm-guard	security	3151	输入/输出安全拦截
k8s-sigs agent-sandbox	sandbox	3077	K8s Sandbox CRD 规范
seekdb	memory	2784	分布式 DB 内建 AI 搜索
OpenLIT	observability	2579	GPU+LLM 全栈监控
google/ax	sandbox	1838	Google 分布式 Agent 运行时
Envoy AI Gateway	gateway	1813	Envoy Filter 透明 LLM 拦截
e2b-dev/infra	sandbox	1219	Firecracker 沙箱事实标杆
sandbox-sdk	sandbox	1059	Cloudflare V8 isolates 边缘
agent-aegis	sandbox	954	Agent 全生命周期安全插件
WindowsAgentArena	sandbox	878	Windows Agent 评测平台
agentscope-runtime	sandbox	831	Python Agent 运行时
MCP Gateway Registry	gateway	772	MCP Server OAuth 联邦
powermem	memory	738	OceanBase 数据库基因记忆
cwc-long-running-agents	sandbox	472	Anthropic 长运行 Agent
NoKV	memory	442	AI 原生分布式文件系统
bedrock-agentcore-starter-toolkit	sandbox	498	AWS AgentCore 旧版 CLI
cohere-terrarium	sandbox	312	最轻量 Python 沙箱
openkruise/agents	sandbox	230	K8s Operator 沙箱
shell	sandbox	213	沙箱化 Shell 执行
agentcore-cli	sandbox	204	AWS AgentCore CLI
OpenShell-Community	sandbox	171	OpenShell 社区发行版
agentscope-runtime-java	sandbox	168	Java AgentScope 运行时

项目	Sub	Stars	核心一句话
DTVM	sandbox	158	WASM 确定性执行
agentkit-sdk-python	sandbox	157	火山引擎 Agent SDK
agentcube	sandbox	154	Volcano GPU 批量调度

五、交叉分析:跨子领域的模式与张力

5.1 凭据管理:从「沙箱的附庸」到「横跨 Sandbox+Gateway+Security 的第一需求」

凭据(API key/OAuth token)不应该被 Agent 拿到——这个共识在三个子领域分别兑现：- **Sandbox 层**:OpenShell(出网关注入)、NemoClaw(加密注入不落盘)、OpenSandbox(Credential Vault) - **Gateway 层**:LiteLLM(Virtual Key)、MCP Gateway Registry(OAuth 联邦认证) - **Security 层**:llm-guard(vault 脱敏)、agent-aegis(tool call 审计)

但三层之间还没有统一凭据管理标准——Key 该在网关注入还是沙箱边界注入?短期 token 的 refresh 谁负责?凭据泄露告警如何跨层关联?**凭据管理可能是 Agent Runtime 生态最需要统一标准的跨层能力。**

5.2 隔离强度:从「一层」到「纵深」

单个沙箱不再是安全的全部答案。深度防御金字塔正在形成:

- L1: 代码执行隔离 (Sandbox 四方向)
- L2: 网络出口控制 + 凭据注入 (Gateway + Supervisor Network)
- L3: 行为审计 + 策略审批 (OCSF + OPA + agent-aegis)
- L4: 内容安全输入/输出拦截 (llm-guard)


OpenShell 是这个纵深模型最接近完整实现的单一项目(同时覆盖 L1+L2 并有 L3 审计能力)。

5.3 OTel:可观测性的统一数据总线

Phoenix(OpenInference)、OpenLLMetry(LLM Span 类型)、TruLens(OTel 后端)都在推动 OTel 成为 LLM 可观测性的统一标准。但 Sandbox/Gateway/Memory 层对 OTel 的采纳程度参差不齐——大部分沙箱项目仍使用自定义日志格式,没有统一的可观测性输出。

5.4 Protocol × Gateway × Sandbox 的理想三角

MCP 和 A2A 填补了通信标准的空白,但协议的落地需要 Gateway(路由/认证/审计)和 Sandbox(安全执行 MCP Server)的配合。目前三者是独立演进的,理想图景是:



六、趋势与展望

- 凭据与沙箱解耦不可逆**:Agent 不应持有 API key 正在成为设计准则,出口网关注入/短期 token 代理/占位符重写三条路线会融合。
- MCP 生态爆发**:月 SDK 下载 9700 万+,从协议变成平台,MCP Server 会像 npm 包一样爆炸增长,催生 MCP Registry/Gateway/治理层的需求。
- 隔离纵深化**:单靠沙箱不够,网络出口+凭据注入+行为审计+内容安全构成四层纵深,OpenShell 是最接近完整实现的方案。
- 原文 vs 摘要之争**:mempalace 96.6% R@5 为原文路线背书,但对话轮数扩大后的存储成本和检索精度是未知数;LLM 上下文窗口持续扩大(128K→1M)可能改变整个博弈。
- OTel 统一化**:Tracing 维度 OTel 统一已成定局,评估维度的标准化(Agent 专项基准)是下一个战场。
- GPU 沙箱仍处早期**:AgentCube/OpenShell VFIO 都在尝试,但 GPU 虚拟化粒度远不如 CPU/内存,多租户 GPU 安全隔离是开放问题。
- 间接注入成为首要安全威胁**:OWASP LLM Top 10(2025)+RL 攻击跨模型迁移(RL-Hammer 98%对 GPT-4o)让内容安全从次要需求升级为核心刚需。

七、快速选型指南

场景	Sandbox	Memory	Gateway	Observability
本地编码 Agent	sandbox-runtime	mem0	LiteLLM	Langfuse
多租户 SaaS	E2B/OpenSandbox	mem0/memU	LiteLLM+Hipress	Phoenix+Opik
K8s 集群	k8s-sigs/openkruise	OpenViking/seekdb	Higress	Langfuse

场景	Sandbox	Memory	Gateway	Observability
GPU Agent	OpenShell	OpenViking	LiteLLM	OpenLIT
企业合规	E2B+agent-aegis	TencentDB-Agent-Memory	MCP Gateway Registry	promptfoo+TruLens
全本地隐私	sandbox-runtime	mempalace/TencentDB-Agent-Memory	LiteLLM(本地)	Langfuse(self-host)
轻量 Python	cohere-terrarium	powermem	LiteLLM	DeepEval
边缘计算	sandbox-sdk	mem0(轻量)	-	-

八、参考资料

- 72 项目 summary.md(KG projects/agent-runtime/*/)
- 49 codebase-memory zst 代码图
- GitHub 实时数据(stars/活跃度/语言,刷新于 2026-07-07)
- agent-runtime 8 份子领域调研:artifacts/02-{sandbox,memory,gateway,observability,tool,protocol,planner,security}.md
- OWASP LLM Top 10 (2025)
- LongMemEval / LoCoMo 记忆性能基准