

Agent Runtime 技术全景

Agent Runtime – 执行隔离与安全 (Sandbox)

关键问题

Agent 沙箱子领域要解决一个核心矛盾：**AI Agent 需要执行不可信代码（LLM 生成、用户提交、第三方插件），但执行环境必须与宿主机和其他 Agent 安全隔离**。这个矛盾在 Agent 场景下尤其尖锐 – Agent 不是被动 API 调用者，而是**主动生成和执行代码的自主实体**，它可能安装依赖、读写文件、发起网络请求、启动子进程。沙箱的挑战不是「能不能隔离」，而是如何在**隔离强度、启动延迟、运维成本、功能完整性**四者之间找到对应场景的最优解。

技术方向分类

方向 1: MicroVM 硬件级隔离 – 安全优先，牺牲启动速度

核心思路：每个 Agent 沙箱是一个独立的轻量级虚拟机（Firecracker / Kata / gVisor），利用硬件虚拟化实现最强的安全边界。Agent 在 VM 内可以拥有完整的 Linux 环境，但无法逃逸到宿主机。VM 销毁后所有状态清零。

代表项目： - e2b-dev/infra (E2B, ~7.5k stars)：Agent 沙箱领域的事实标杆。基于 Firecracker microVM，<200ms 冷启动，API-first（`sandbox.create()` / `sandbox.runCode()`），提供 Python/Node.js/Go 等多语言预构建环境模板和 TypeScript/Python/Go SDK。 - NVIDIA/OpenShell (~20k stars)：Rust 编写的多后端沙箱运行时。microVM 只是其四种驱动之一（另有 Podman/Docker/K8s），核心差异化在于**凭据代理出口网关** – Agent 的 LLM API key 在网络边界注入，Agent 本身看不到原始凭据。还包括 GPU VFIO 直通、OPA 策略引擎和 OCSF 审计。 - opensandbox-group/OpenSandbox：协议驱动的通用沙箱平台。支持 gVisor（约 550ms 冷启动）、Kata Containers（QEMU VM）和 Firecracker（约 625ms）三种增强隔离模式。控制面/数据面分离的三层架构，提供 5 种语言 SDK 和 MCP Server 原生集成，是开源社区中覆盖面最广的 Agent Sandbox 方案。

适用场景： - 多租户 SaaS 平台（每个用户/Agent 获得独立 VM） - 金融、医疗等高合规要求场景 - 执行来自外部的不受信任代码（如用户提交的脚本、第三方 Agent 插件）

局限： - 冷启动延迟即使优化到 <200ms，仍高于容器/进程方案 - 大规模并发（1000+沙箱）下的资源碎片化和调度延迟是未解决的工程难题 - VM 级隔离的运维复杂度显著高于容器方案

方向 2：容器级隔离 – 主流平衡点，生态成熟

核心思路：利用 Docker / Kubernetes / Podman 等成熟容器技术实现沙箱。相比 MicroVM，容器共享宿主机内核因此启动更快（秒级）；相比进程级隔离，文件系统、网络、cgroup 资源限制更完整。这是目前采用最广泛的路线。

代表项目：

- `kubernetes-sigs/agent-sandbox` (Kubernetes SIG)：定义 Agent 沙箱的 K8s 原生 CRD 规范。通过 Sandbox CRD 声明沙箱的运行类型（container/vm/microvm）和安全策略，利用 RuntimeClass 集成 Kata/gVisor/Firecracker。代表了 K8s 社区对 Agent 沙箱标准化的官方态度。
- `openkruise/agents`：K8s Operator 模式的 Agent 沙箱。通过 Sandbox CRD 管理沙箱完整生命周期（Create -> Ready -> Running -> Idle -> Terminated），自动回收空闲沙箱。支持 GPU/NPU（昇腾 Ascend）资源声明，内置 seccomp/AppArmor/SELinux 安全策略模板。
- `coder/coder` (~8.5k stars)：开发环境即代码平台，以 Terraform 模板定义工作空间，在 K8s/Docker/VM 上按需创建隔离 Agent 执行环境。支持 VS Code/JetBrains/SSH 接入，空闲自动休眠。冷启动约 30s-2min（偏重，非为 Agent 场景优化）。
- `cohere-ai/cohere-terrarium` (~300 stars)：轻量 Python 代码沙箱，双运行时架构（Docker + Pyodide 浏览器端）。专为 LLM Data Agent 设计，提供 `/run` HTTP API，Agent POST 代码获取 stdout/stderr。代码精简，部署门槛极低。
- `volcano-sh/agentcube`：基于 CNCF Volcano 批量调度系统的 Agent 沙箱。差异化在于 GPU/CPU 混合资源管控和批量 Agent 任务优先级调度。
- `TencentCloud/CubeSandbox`：腾讯云的 Agent 安全沙箱方案。容器安全增强 + seccomp/AppArmor + 可插拔运行时（Python/Node.js/Go 模板）。与腾讯云基础设施有潜在绑定。
- `NVIDIA/NemoClaw` (~21.5k stars)：OpenShell 容器之上的安全 Agent 运行时封装。细粒度权限控制（文件路径 + 网络地址 + 系统调用白名单），凭证通过加密通道注入沙箱且不落盘。
- `anthropics/cwc-long-running-agents`：Anthropic 的长时间运行 Agent 参考实现，Docker 沙箱 + Claude Computer Use 协议。核心价值在于任务中断恢复、检查点管理和 Human-in-the-Loop 审查模式。
- `strands-agents/shell`：沙箱化 Shell 执行组件，遵循 strands-agents 统一的 Tool 接口规范。容器内执行任意 Shell 命令，支持临时会话（用完即毁）和持久化会话。
- `agentscope-ai/agentscope-runtime`：Python 的 Agent 运行时框架，Docker/nsjail 双沙箱引擎。OpenTelemetry 全链路可观测，中间件链模式（鉴权/限流/审计）。
- `agentscope-ai/agentscope-runtime-java` (~167 stars)：Java 版 AgentScope 运行时。基于 Java SecurityManager + 自定义 ClassLoader 隔离（但 SecurityManager 在 JDK 17+ 已 deprecated），gRPC 通信层，面向企业 Spring Boot 集成。

适用场景：

- 绝大多数 Agent 代码执行场景（Coding Agent、数据分析、自动化脚本）
- 已有 K8s 基础设施的团队
- 需要在隔离性和启动速度之间取得工程平衡的中等安全需求

局限：

- 共享宿主机内核，容器逃逸漏洞历史上屡见不鲜
- K8s 方案的冷启动（Pod 调度 + 镜像拉取）往往在数秒到数十秒，对亚秒级交互式 Agent 不够友好
- 多运行时后端的统一抽象层稳定性和行为一致性是普遍的工程难题

方向 3：进程级轻量隔离 – 速度优先，零基础设施依赖

核心思路：利用 OS 原生安全基元（macOS Seatbelt / Linux bubblewrap / seccomp）或语言级沙箱（WASM / V8 isolates）实现隔离。不需要 Docker，不需要 VM，不需要 K8s – 直接包装任意进程。启动延迟接近零，是最好的开发者体验方案，但隔离强度也是最低的。

代表项目： - anthropic-experimental/sandbox-runtime (~2k stars): Anthropic 为 Claude Code 开发的进程级沙箱。macOS 使用 sandbox-exec 动态生成 Seatbelt 配置文件，Linux 使用 bubblewrap + 网络命名空间。HTTP + SOCKS5 双代理网络过滤，TLS Termination（实验性 MITM 解密），npm 全局安装即用。安全默认策略（网络/文件写入全部拒绝，allow-only 模式）。代表了「不需要容器」路线的最高工程水平。 - DTMStack/DTVM (~158 stars): 面向 AI Agent 的确定性虚拟机。以 WASM 为字节码格式，利用 WASM 的沙箱隔离和确定性执行语义。核心创新在于「确定性系统接口 (DSI)」– 封装文件系统、时钟、随机数等非确定性系统调用，提供确定性替代实现，确保 Agent 操作可审计、可复现。支持 VM 状态快照与回滚。 - cloudflare/sandbox-sdk: Cloudflare 的边缘沙箱 SDK。基于 Cloudflare Workers 的 V8 isolates 机制，毫秒级启动，全球 330+ 边缘节点部署。每个沙箱运行在独立 isolate 中。与 Cloudflare 生态深度绑定，适合已使用 CF 的团队。

适用场景： - 本地开发者 Agent（Claude Code、Cursor、Copilot 等编码助手） - MCP Server 的安全包装（一行命令 srt 即沙箱化） - 边缘计算场景（Cloudflare Workers） - 对启动延迟敏感（<100ms）且不需要 root 权限的 Agent

局限： - 隔离强度显著低于 VM 和容器：macOS Seatbelt 和 Linux bubblewrap 的设计目标不是防御恶意代码，而是防御意外操作 - 不支持需要内核模块或特权操作的 Agent 工作负载 - WASM 路线（DTVM）的 GPU 推理和部分 C 扩展包支持受限 - Cloudflare sandbox-sdk 锁定 CF 生态，非 CF 用户无法使用

方向 4：安全策略、标准化与平台托管 – 不造轮子，用现成的

核心思路：不直接提供沙箱执行环境，而是在现有沙箱之上提供安全策略、标准化接口或全托管平台。这是 Agent 沙箱生态的「上层建筑」。

代表项目： - antgroup/agent-aegis: Agent 全生命周期安全防护插件。以轻量级插件形式嵌入 Agent 框架，覆盖 prompt 注入检测 -> 工具调用拦截 -> 输出内容过滤。TypeScript 实现，针对金融场景定制。与底层沙箱互补 – aegis 管「Agent 行为安全性」，沙箱管「代码执行安全性」。 - agent-infra/sandbox: 社区驱动的 Agent 沙箱 API 标准化尝试。定义 sandbox.create / sandbox.run / sandbox.destroy 的通用接口规范（类似 OCI 之于容器），目标是「Agent 框架和沙箱实现的解耦」。目前共识程度有限，主要沙箱厂商（E2B/腾讯/K8s）尚未明确表态采纳。 - **AWS Bedrock AgentCore 生态**（3 个项目）： - aws/agentcore-cli: 新一代 CLI 工具，本地 agentcore dev -> 云端 agentcore deploy 一条命令 - awslabs/agentcore-samples: 官方示例集，覆盖代码执行沙箱、多工具编排、可观测性等最佳实践 - aws/bedrock-agentcore-starter-toolkit: 旧版 Python CLI 工具包，项目脚手架 + 本地调试 + CI/CD 三者共同构成 AWS 的 Agent 托管平台入口，底层基于 Firecracker microVM，但用户无需关心 – 全托管。 - volcengine/agentkit-sdk-python: 火山引擎的 Agent 开发工具包。CLI 脚手架 + @tool 装饰器工具注册 + Docker/进程级沙箱执行 + OpenTelemetry 可观测。MCP 协议兼容。定位面向 Python 开发者的 Agent 快速启动体验。 - google/ax: Google 的分布式 Agent 运行时。将 Agent

抽象为可分布执行的单元，每个 Agent 在独立沙箱中运行，通过 gRPC 通信。基于 DAG 的任务依赖管理，支持多执行后端（本地进程/容器/云端）。可插拔架构。 - microsoft/WindowsAgentArena：微软研究院的 Windows Agent 评测平台。在 Azure Windows VM 中运行 Agent，通过磁盘快照回滚保证测试隔离。150+ 预定义任务，规模化并行测试（数百个 VM 实例）。本质是特殊用途的沙箱 – 评测而非生产执行。 - agentscope-ai/AgentTeams：协作式多智能体操作系统。核心不在沙箱本身，而是多 Agent 协作协议和 Human-in-the-Loop 机制。每个 Agent 在隔离上下文中执行，但隔离策略由平台统一管理。

适用场景： - 不想自建基础设施、愿意使用云厂商托管方案的团队 - 需要在现有沙箱之上增加安全策略层（Agent 行为安全 vs. 代码执行安全） - 需要标准化接口以实现沙箱厂商可替换的 Agent 框架开发者

局限： - 云厂商方案（AWS/火山引擎/Cloudflare）的供应商锁定风险 - Agent 沙箱 API 标准化（agent-infra/sandbox）的社区共识远未形成 - 安全策略层（agent-aegis）无法替代底层沙箱隔离，只能作为补充

当前趋势与开放争议

趋势

1. **凭据管理与沙箱解耦：** OpenShell 的出口网关注入、OpenSandbox 的 Credential Vault MITM 代理、NemoClaw 的加密凭证注入 – 多个项目不约而同地把「Agent 不应该看到 API key」作为核心设计约束。这正在成为 Agent 沙箱的标配能力，而不仅是安全加固选项。
2. **多后端可插拔成为共识：** OpenShell（microVM/Podman/Docker/K8s 四后端）、OpenSandbox（Docker+K8s 双重后端）、kubernetes-sigs/agent-sandbox（RuntimeClass 集成 gVisor/Kata/Firecracker） – 同一个沙箱接口支持不同隔离等级的后端切换，正在成为主流架构模式。
3. **从「能隔离」到「可观测」：** OpenTelemetry 集成几乎成为标配（ax、agentscope-runtime、AgentScope Runtime Java、agentkit-sdk-python、OpenSandbox），沙箱不仅要安全执行，还要让 Agent 的每一步操作可追踪、可审计。
4. **边缘 + 沙箱的融合：** Cloudflare sandbox-sdk 把代码执行推到了 CDN 边缘节点，Terrarium 的 Pyodide 模式在浏览器内运行 Python – 沙箱不一定是后端服务，也可以是前端能力。

争议

1. **隔离强度 vs. 启动速度的不可调和矛盾：** MicroVM（E2B <200ms 冷启动）和进程级（sandbox-runtime 零启动）之间存在本质性的安全/速度权衡。争议在于：对于编码 Agent（最主流的沙箱使用场景），是否真的需要 VM 级隔离？还是容器级甚至进程级就足够？目前没有行业共识。
2. **标准化 vs. 碎片化：** agent-infra/sandbox 试图定义统一的 Sandbox API，但 E2B 有自己的 API，OpenSandbox 有自己的 OpenAPI 规范，K8s 有自己的 Sanbbox CRD。Agent 框架开发者

面临「选哪个沙箱后端」的碎片化困境。标准化成功与否取决于大厂（E2B/Anthropic/K8s社区）是否愿意妥协采纳统一接口。

- 3. **GPU 沙箱的工程挑战**: AgentCube 和 OpenShell 都在尝试 GPU 沙箱（GPU 显存分配、VFIO 直通、MIG 隔离），但 GPU 虚拟化的粒度远不如 CPU/内存。多租户 GPU 集群中的安全隔离（防止显存侧信道攻击、GPU 时间片公平分配）仍是开放问题。
- 4. **确定性的价值与代价**: DTVM 提出「Agent 代码执行应该确定性可复现」，这对审计和调试极具吸引力。但确定性意味着要裁剪掉大量非确定性系统调用（时钟、随机数、某些网络 I/O 模式），这在实际 Agent 场景中可能严重限制功能。确定性沙箱是未来方向还是过度设计，尚无定论。
- 5. **安全策略的边界划分**: Agent 安全应该由沙箱底层保证（隔离执行），还是由策略插件保证（行为审计），还是两者兼有？agent-aegis（策略层）和 sandbox-runtime（隔离层）代表了两种不同的安全哲学。实际生产中，两者不是互斥而是互补，但「谁该负责什么」的边界共识正在形成中。

项目全景表

项目	Stars	隔离层级	核心差异	活跃度
NVIDIA/OpenShell	~20k	MicroVM/Container 多后端	凭据代理出口网关 + GPU VFIO 直通 + OPA 策略引擎	高 (Rust 多 crate 工作区, 15+ 模块)
NVIDIA/NemoClaw	~21.5k	Container (OpenShell)	OpenShell 之上的安全封装, 细粒度权限白名单, 凭证不落盘	中
e2b-dev/infra	~7.5k	MicroVM (Firecracker)	<200ms 冷启动, API-first, Agent 沙箱的事实标杆	高 (Go, ~94k 行代码)
coder/coder	~8.5k	Container/VM (Terraform)	开发环境即代码, Terraform 模板化工作空间	高
opensandbox-group/OpenSandbox	~1k+	Container + 增强隔离 (gVisor/Kata/Firecracker)	协议驱动, 5 语言 SDK + MCP 原生集成, Credential Vault	中高
kubernetes-sigs/agent-sandbox	~500+	Container/VM (K8s RuntimeClass)	K8s 原生的 Agent Sandbox CRD 规范, 社区标准化方向	中

项目	Stars	隔离层级	核心差异	活跃度
openkruise/agents	~300+	Container (K8s Operator)	Sandbox CRD 生命周期自动化, GPU/NPU 支持, seccomp/AppArmor	中
anthropic-experimental/sandbox-runtime	~2k	进程级 (OS 原生)	零容器零 VM, macOS Seatbelt + Linux bubblewrap, Claude Code 安全底座	中高 (TypeScript+Rust)
cloudflare/sandbox-sdk	~500+	V8 Isolates (边缘)	全球 330+ 边缘节点, 毫秒级启动, Cloudflare 生态绑定	中
DTVMStack/DTVM	~158	WASM 字节码	确定性执行, 状态快照与回滚, 跨语言 WASM 统一抽象	低 (早期)
cohere-ai/cohere-terrarium	~300	Container (Docker) + 浏览器 (Pyodide)	双运行时架构, 轻量极简, 专为 LLM Data Agent 设计	低
TencentCloud/CubeSandbox	~200+	Container (腾讯云增强)	腾讯云容器安全增强方案, 可插拔运行时模板	低
volcano-sh/agentcube	~100+	Container (K8s Volcano)	GPU/CPU 混合资源管控, 批量 Agent 任务优先级调度	低
antgroup/agent-aegis	~300+	安全策略层 (插件式)	Agent 全生命周期安全防护, prompt 注入检测 + 工具调用审计 + 输出过滤	低
anthropics/cwc-long-running-agents	~500+	Container (Docker)	长时间运行 Agent 参考实现, 任务中断恢复 + HITL	低
aws/agentcore-cli	~100+	平台托管 (Firecracker)	AWS Bedrock AgentCore CLI 入口, 本地开发 + 云端部署	中
awslabs/agentcore-samples	~100+	平台托管 (Firecracker)	AWS Bedrock AgentCore 官方示例和最佳实践	低

项目	Stars	隔离层级	核心差异	活跃度
aws/bedrock-agentcore-starter-toolkit	~50+	平台托管 (Firecracker)	AWS Bedrock AgentCore Python CLI 工具包 (旧版)	低
volcengine/agentkit-sdk-python	~500+	Container/进程级	火山引擎 Agent SDK, CLI 脚手架 + 工具注册 + MCP 兼容	中
google/ax	~1k+	Container/进程/云	Google 分布式 Agent 运行时, DAG 任务调度 + 可插拔后端	中
agentscope-ai/agentscope-runtime	~200+	Container (Docker/nsjail)	Python Agent 运行时, OpenTelemetry 全链路可观测	低
agentscope-ai/agentscope-runtime-java	~167	JVM 级 (SecurityManager)	Java 企业版 Agent 运行时, Spring Boot 集成 + gRPC	低
agentscope-ai/AgentTeams	~500+	平台管理 (隔离上下文)	多 Agent 协作 OS, Human-in-the-Loop 深度集成	低
microsoft/WindowsAgentArena	~500+	VM (Azure Windows + 快照回滚)	Windows Agent 基准评测平台, 150+ 任务, 规模化并行测试	低
agent-infra/sandbox	~100+	API 规范层	Agent 沙箱标准化接口规范, 可插拔后端设计	极低
strands-agents/shell	~50+	Container (Docker)	沙箱化 Shell 执行组件, Tool 接口标准化	极低
NVIDIA/OpenShell-Community	~50+	Container (Docker)	OpenShell 社区发行版, 更快的更新节奏	极低

注：Star 数量为近似值，部分低星项目的精确数字需从 GitHub 实时获取。活跃度基于代码 commit 频率、社区参与度和项目阶段综合判断。

按场景的选型建议

场景	推荐技术方向	首选项目	备选
本地编码 Agent (Claude Code 等)	进程级轻量隔离	sandbox-runtime	-

场景	推荐技术方向	首选项目	备选
生产多租户 SaaS (强安全)	MicroVM 硬件隔离	e2b-dev/infra	OpenSandbox (gVisor/Firecracker)
K8s 集群 Agent 沙箱	容器级 (K8s 原生)	kubernetes-sigs/agent-sandbox	openkruise/agents
GPU Agent 沙箱	MicroVM + GPU 直通	NVIDIA/OpenShell	volcano-sh/agentcube
企业级 Java Agent	JVM 容器级	agentscope-runtime-java	coder/coder
轻量 Python 数据分析 Agent	容器级	cohere-terrarium	agentscope-runtime
边缘计算 Agent	进程级 (V8/WASM)	cloudflare/sandbox-sdk	DTVM
Agent 安全审计 (已有沙箱)	安全策略插件	antgroup/agent-aegis	-
不想运维基础设施	平台托管	AWS Bedrock AgentCore	火山引擎 AgentKit
Agent 评测	VM 快照回滚	WindowsAgentArena (Windows)	-