

SGLang 技术动态

sgl-project/sglang 技术动态摘要

周期: 2026-01-01 ~ 2026-06-30 | 数据源: Releases / Issues / PRs / Discussions

版本变化

版本	日期	类型	间隔
v0.5.14	06-26	stable	13 天
v0.5.13	06-13	stable	18 天
v0.5.12.post1	05-26	stable	10 天
v0.5.12	05-16	stable	11 天
v0.5.11	05-05	stable	—

发版节奏：约 **11-18** 天一个 **stable release**，2026 年上半年保持高频迭代。

PR 方向聚类 (上周, 50 PRs 采样)

方向	PR 数	占比	趋势
CI/测试	30	60%	🔥 最高
文档	11	22%	
DeepSeek 适配	6	12%	⬆️ 上升
Diffusion 模型	5	10%	⬆️ 新增方向
NPU 支持	4	8%	⬆️ Ascend
AMD GPU	3	6%	
Blackwell (NVFP4)	3	6%	NEW
量化	3	6%	

方向	PR 数	占比	趋势
多模态	2	4%	

本周特征： - CI/测试占主导（60%），说明处于质量加固期 - DeepSeek 适配和 Diffusion 是增长方向 - NPU (Ascend) 和 AMD 的硬件适配活跃 - Blackwell NVFP4 是新出现的硬件支持方向

社区热点 (Issues)

Discussions 活跃度较低（👍 均为 0），Issue 按 reactions 排序无高热度结果。说明 SGLang 社区的讨论主要在 PR review 中发生，而非独立的 Issue/Discussion 线程。

竞争分析: SGLang vs vLLM

维度	vLLM	SGLang
最新版本	v0.24.0 (06-29)	v0.5.14 (06-26)
发版节奏	~14 天	~13 天
硬件支持	NVIDIA CUDA + Ascend + Intel	NVIDIA CUDA + AMD + NPU + Blackwell
差异化	PagedAttention (SOSP 2023)	RadixAttention + 压缩 FSM (NeurIPS 2024)
亮点趋势	版本号跳变大 (v0.23→v0.24)	DeepSeek/Diffusion 新方向

差距变化： - vLLM 在推理吞吐量上仍有文章优势（2-4× baseline），SGLang 在结构化输出（JSON/Regex 约束解码）和 Agent 多轮推理场景有 6.4× 优势 - SGLang 发版节奏与 vLLM 基本持平（~2 周），社区活跃度相当 - SGLang 近期在 **Diffusion 模型** 和 **多模态** 方向投入增加，可能是新的差异化点 - vLLM 版本号从 v0.23→v0.24 跳变大，暗示有较大架构变更

结论

- 高频迭代稳定：SGLang 保持 ~2 周一版的节奏，v0.5.x 系列趋于成熟
- 质量加固期：本周 60% PR 为 CI/测试，可能为 v0.6 大版本做准备
- DeepSeek 战略投入：连续多周有 DeepSeek 相关 PR，说明团队重点适配国产大模型

4. 竞争格局：vLLM 和 SGLang 在各自优势领域保持领先，尚未出现一方全面压倒另一方的趋势

KG System | 2026-06-30 | /kg-watch sgl-project-sglang